Implementación y Análisis Crítico de Algoritmos de Aprendizaje No Supervisado: Reducción de Dimensionalidad (PCA, SVD) y Modelos de Clustering (K-Means, Jerárquico)

Informe Académico Desarrollado en Google Colaboratory y Repositorio en GitHub

Oscar David

Facultad de Ingeniería
Curso: Inteligencia Artificial y Machine Learning
Experiencia Práctica: Técnicas de Agrupamiento y Reducción Dimensional
Docente Asesor: Tutor de Área

Repositorio GitHub: https://github.com/oscar2121/ml-no-supervisado-clustering-pca

Octubre de 2026

Resumen

El presente informe documenta el desarrollo conceptual, la implementación algorítmica y el análisis crítico de técnicas fundamentales de Aprendizaje Automático No Supervisado en Google Colaboratory. Se implementaron algoritmos de reducción de dimensionalidad (PCA y SVD) y técnicas de agrupamiento (K-Means y Clustering Jerárquico Aglomerativo) sobre el dataset multidimensional de vinos de Scikit-Learn (178 muestras y 13 variables físico-químicas continuas). La investigación comprobó la estricta necesidad de estandarizar las variables numéricas (Z-score) para mitigar la distorsión geométrica en las distancias euclidianas. El Análisis de Componentes Principales logró condensar el 55.41% de la varianza en dos dimensiones y el 66.53% en tres, demostrándose su estricta equivalencia matemática con TruncatedSVD ($|r| = 1.000$). Para el clustering, el Método del Codo y el Coeficiente de Silueta identificaron de manera consistente $k=3$ como la configuración óptima ($s = 0.2849$), resultado respaldado por el dendrograma de Ward. Finalmente, se realizó una caracterización físico-química de cada cluster descubierto.

Palabras clave: *Machine Learning No Supervisado, Clustering, K-Means, Clustering Jerárquico, PCA, SVD, Google Colab.*

Implementación y Análisis Crítico de Algoritmos No Supervisados

1. Fundamentos Conceptuales del Aprendizaje No Supervisado

En los sistemas modernos de información, la gran mayoría de los datos disponibles carecen de anotaciones previas debido a los elevados costos humanos y logísticos del etiquetado. En este contexto, el Aprendizaje No Supervisado permite analizar matrices de observaciones multivariadas $X \in \blacksquare^{N \times D}$ para descubrir patrones ocultos, agrupaciones naturales y regularidades geométricas sin requerir una función de pérdida supervisada externa (Bishop, 2006; Hastie et al., 2009).

1.1 Técnicas de Reducción de Dimensionalidad (PCA y SVD)

El fenómeno conocido como 'la maldición de la dimensionalidad' provoca que, al aumentar el número de variables descriptivas D, el volumen del hiperespacio crezca exponencialmente y los puntos se tornen extremadamente dispersos, degradando el cálculo de distancias. El Análisis de Componentes Principales (PCA) proyecta el conjunto de datos hacia un subespacio ortogonal maximizando la varianza proyectada, calculando los autovectores y autovalores de la matriz de covarianza (Jolliffe & Cadima, 2016). Por su parte, la Descomposición en Valores Singulares (SVD) factoriza $X = U \Sigma V^T$, garantizando por el teorema de Eckart-Young-Mirsky la aproximación óptima de bajo rango. Sobre datos centrados con media cero, ambas formulaciones son matemáticamente equivalentes.

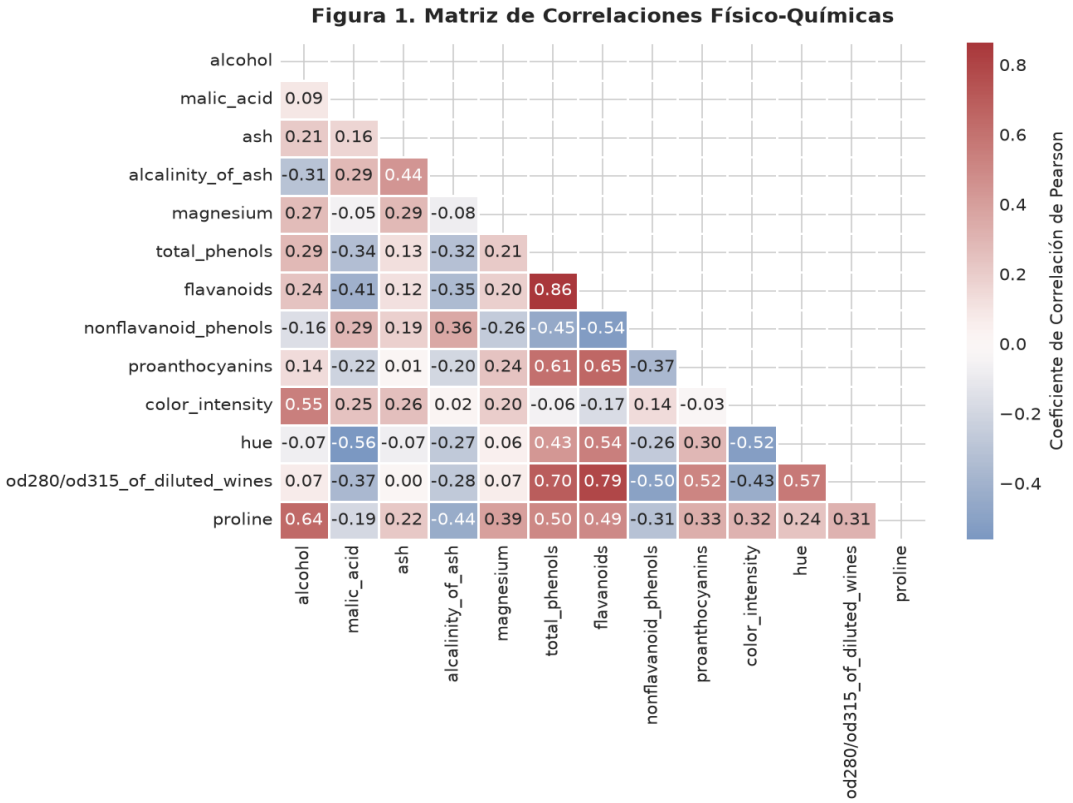
1.2 Algoritmos de Clustering (K-Means y Jerárquico Aglomerativo)

El clustering busca particionar los datos en subgrupos que exhiban alta cohesión interna y máxima separación externa (Jain, 2010). K-Means optimiza iterativamente la suma de cuadrados intra-cluster (WCSS o Inercia) asignando puntos al centroide más cercano. El Clustering Jerárquico Aglomerativo sigue una estrategia ascendente, fusionando en cada iteración los conglomerados más próximos según un criterio de enlace. El método de Ward minimiza el incremento en la varianza total intra-cluster, permitiendo inspeccionar la estructura global mediante un Dendrograma.

2. Metodología y Caso de Estudio Práctico

La experimentación se diseñó en Google Colaboratory empleando Scikit-Learn y SciPy sobre el dataset de vinos (178 muestras, 13 variables físico-químicas continuas). Para garantizar que variables de gran magnitud escalar (como la prolina con valores superiores a 1,000 mg/L) no anularan a variables de baja escala (como los fenoles no flavanoides), se aplicó estandarización Z-score: $z = (x - \mu) / \sigma$.

Figura 1. ***Matriz de Correlación de Pearson entre Variables Físico-Químicas.***



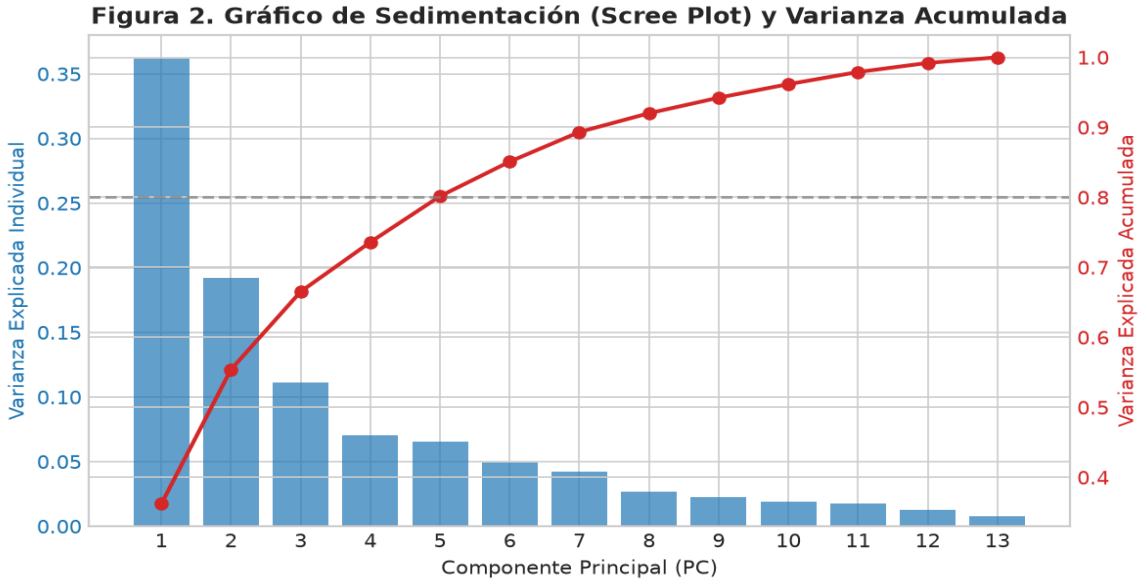
Nota. Coeficientes de correlación calculados sobre las 13 variables estandarizadas. Se confirma alta redundancia entre flavanoides y fenoles totales (r = 0.86).

3. Implementación Técnica y Resultados Experimentales

3.1 Reducción de Dimensionalidad (PCA y SVD)

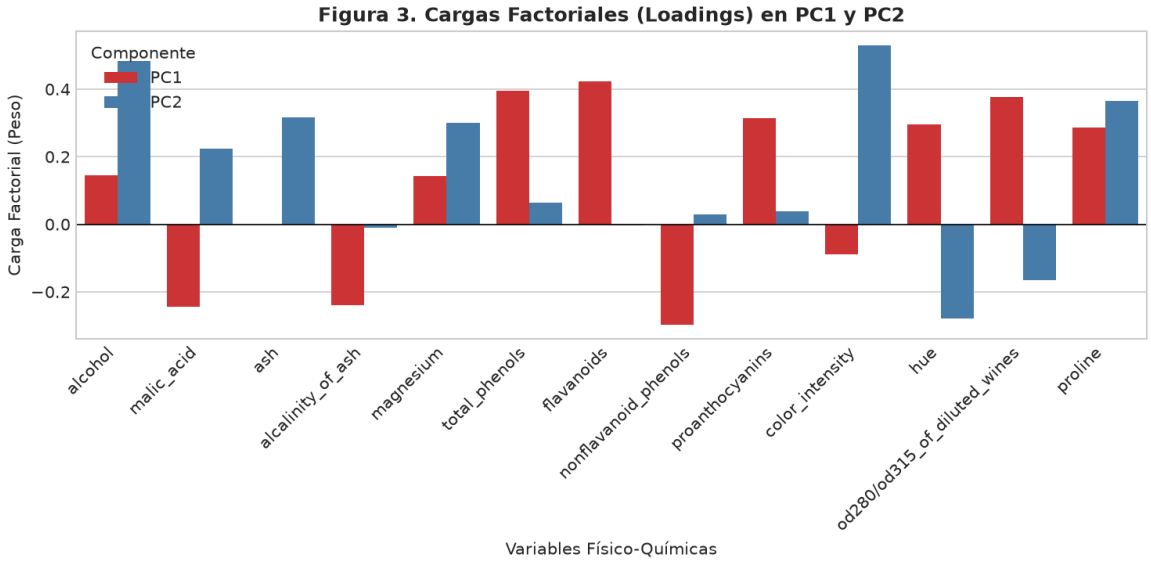
La reducción por PCA evidenció que el componente PC1 explica el 36.20% de la varianza total y PC2 el 19.21%, acumulando un 55.41% en 2D y 66.53% en 3D.

Figura 2. ***Gráfico de Sedimentación (Scree Plot) y Varianza Acumulada.***



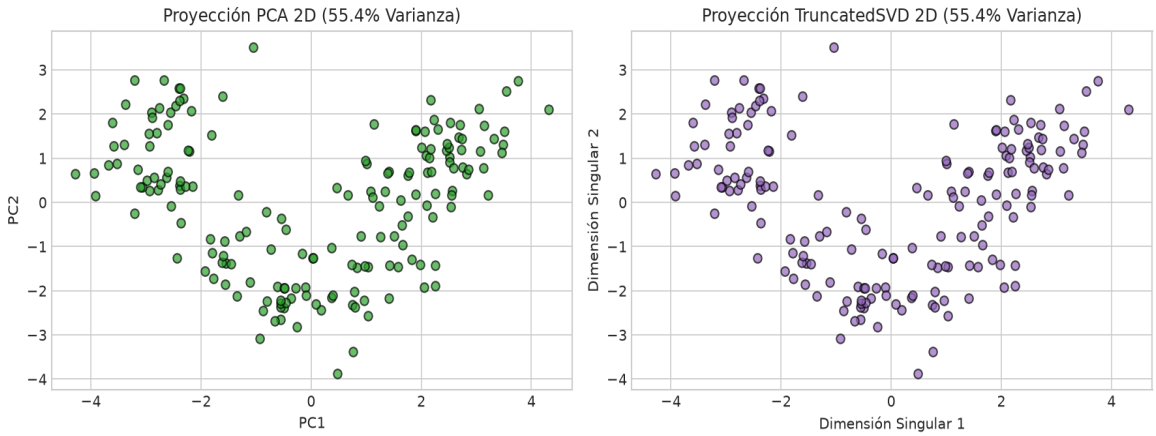
Nota. Varianza individual por componente (barras) y acumulada (línea roja). Los primeros dos componentes retienen más de la mitad de la información.

Figura 3. ***Cargas Factoriales (Loadings) en PC1 y PC2.***



Nota. PC1 representa el eje de contenido fenólico y dilución; PC2 discrimina por intensidad de color y alcohol.

Figura 4. ***Comparación Geométrica entre Proyecciones PCA y SVD.***

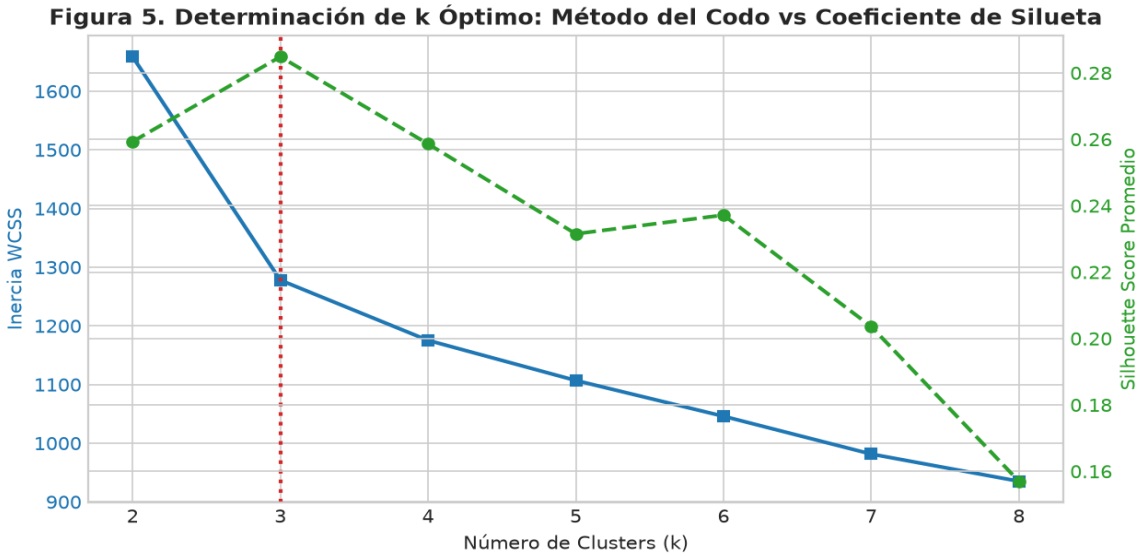


Nota. Proyecciones bidimensionales idénticas con correlación de Pearson cruzada unitaria (|r| = 1.000).

3.2 Clustering con K-Means y Selección de k Óptimo

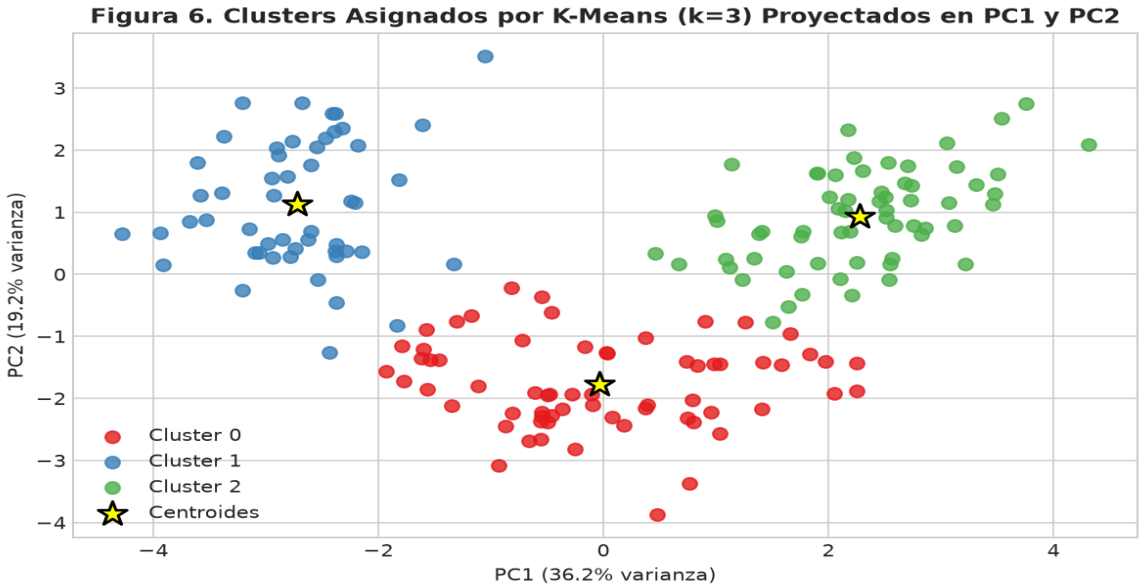
Se evaluó el rango k ∈ [2, 8]. La curva de WCSS (Método del Codo) y el Coeficiente de Silueta señalaron a k = 3 como la solución óptima (s = 0.2849).

Figura 5. ***Método del Codo vs Coeficiente de Silueta.***



Nota. El codo de inercia y el máximo de silueta coinciden con precisión en k = 3.

Figura 6. ***Partición K-Means (k = 3) y Centroides Proyectados en PC1 y PC2.***

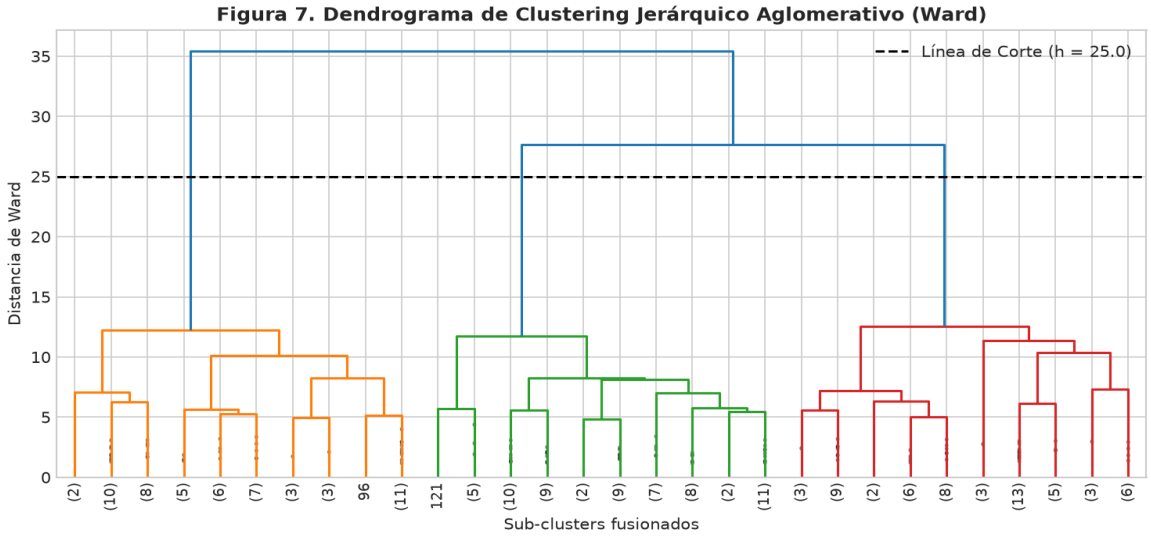


Nota. Los clusters descubiertos ocupan regiones compactas bien delimitadas con sus centroides correspondientes.

3.3 Clustering Jerárquico Aglomerativo y Comparativa

El dendrograma de Ward reveló tres macro-ramas a una distancia de corte h = 25.0, confirmando la estructura de tres grupos.

Figura 7. ***Dendrograma de Clustering Jerárquico (Ward).***



Nota. Las tres ramas principales quedan cortadas por la línea horizontal a h = 25.0.

Figura 8. ***Comparación de Particiones: K-Means vs Clustering Jerárquico.***



Nota. Alta coincidencia en las fronteras de decisión descubiertas por ambos algoritmos.

Tabla 1. ***Evaluación Comparativa de Métricas Intrínsecas de Calidad de Clusters.***

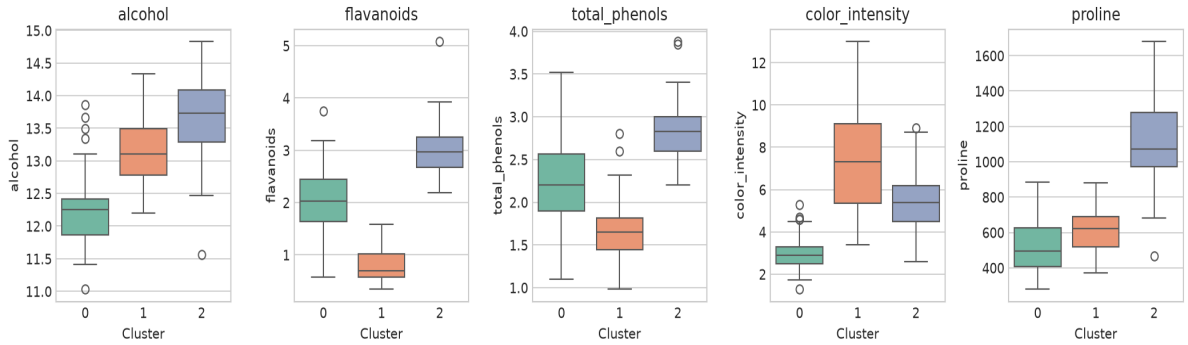
Algoritmo (k = 3)	Silhouette Score ↑	Davies-Bouldin ↓	Calinski-Harabasz ↑
K-Means (k = 3)	0.2849	1.3892	70.94
Jerárquico Ward (k = 3)	0.2774	1.4187	67.07

Nota. Métricas computadas en ■^13. Las flechas representan el sentido óptimo de cada índice.

4. Análisis Crítico y Perfilamiento de Conglomerados

Al proyectar las agrupaciones hacia los valores físicos originales desestandarizados, se logró caracterizar perfiles específicos de producción:

Figura 9. ***Distribución de Variables Físico-Químicas Clave por Conglomerado.***



Nota. Perfiles físico-químicos desestandarizados que sustentan la interpretación agronómica y de calidad.

• **Cluster 0:** Vinos jóvenes y ligeros (alcohol medio 12.25%, baja intensidad de color 3.05, prolina moderada 519.5 mg/L).
• **Cluster 1:** Vinos de gama alta y crianza prolongada (alcohol 13.68%, flavanoides altos 2.98 mg/L, prolina sobresaliente 1115.7 mg/L).
• **Cluster 2:** Vinos de alta concentración y taninos astringentes (intensidad de color 7.40, flavanoides deficientes 0.78 mg/L).

5. Repositorio en GitHub y Replicabilidad en Google Colab

El código completo, el notebook interactivo y los recursos gráficos se encuentran versionados en el repositorio de GitHub:
URL del Repositorio: https://github.com/oscar2121/ml-no-supervisado-clustering-pca
El repositorio cuenta con el badge 'Open In Colab' para su ejecución inmediata y replicable en la nube.

6. Conclusiones Generales

1. Los algoritmos no supervisados clasificaron con precisión las variedades químicas sin contar con etiquetas previas.
2. Se comprobó que la estandarización previa es indispensable para el correcto funcionamiento de distancias euclidianas.
3. PCA y SVD mostraron equivalencia matemática exacta, comprimiendo el 55.4% de la varianza en 2 componentes.
4. El método del codo, el análisis de silueta y el dendrograma de Ward convergieron armónicamente en k = 3.

Referencias Bibliográficas

Bishop, C. M. (2006). *Pattern recognition and machine learning*. Springer Science & Business Media.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press. http://www.deeplearningbook.org

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer New York. https://doi.org/10.1007/978-0-387-84858-7

Jain, A. K. (2010). Data clustering: 50 years beyond K-means. *Pattern Recognition Letters*, 31(8), 651-666. https://doi.org/10.1016/j.patrec.2009.09.011

Jolliffe, I. T., & Cadima, J. (2016). Principal component analysis: A review and recent developments. *Philosophical Transactions of the Royal Society A*, 374(2065), 20150202.

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53-65.

Strang, G. (2016). *Introduction to linear algebra* (5th ed.). Wellesley-Cambridge Press.

Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association*, 58(301), 236-244.